Clasificación de identidad y emoción en rostros

Trabajo Práctico 1 — Grupo 8

IA y Aprendizaje Automático II · UCA Rosario · Noviembre 2026

Resumen

Se entrenaron clasificadores de imágenes para dos tareas sobre rostros de figuras públicas argentinas: *identidad* (20 personas) y *emoción* (alegría, enojo, neutral, sorpresa y tristeza). Se compararon cuatro CNNs diseñadas y entrenadas desde cero, tres modelos con transfer learning y tres baselines, en TensorFlow/Keras sobre una GPU T4 de Colab. En el test del dataset final (411 imágenes), ResNet50V2 —elegida por validación en las dos tareas— alcanza un F1 macro de 0,974 en identidad y 0,482 en emoción. La identidad no muestra sobreajuste; en emoción las CNNs desde cero sobreajustan y los modelos de transferencia quedan cortos aun en train. Los análisis muestran que la identidad se apoya en parte en el fondo del video, por lo que esas cifras están algo infladas. El modelo final se publicó en una aplicación web.

1. Datos

- **Dataset final:** 2723 imágenes de 224×224 de 20 personas. **G8:** 221 imágenes de dos personas (Dolores Fonzi y Pablo Echarri), incluidas también en el final.
- **Limpieza:** se eliminaron 10 duplicados exactos (md5) con etiquetas en conflicto; quedan 2713 imágenes.
- **Desbalance:** por persona, de 63 (Julio Chávez) a 419 imágenes (Guillermo Francella); por emoción, de 340 (tristeza) a 765 (neutral). Por eso la métrica principal es el **F1 macro**, que pesa igual a todas las clases.
- **Partición 70/15/15** (semilla 42; 1889 / 413 / 411 imágenes). Los fotogramas casi idénticos de un mismo video se agrupan con un hash perceptual (*phash*, distancia ≤ 8) y cada grupo va entero a una sola partición: ningún grupo queda repartido, así el test no contiene copias del train. La asignación se hace por persona, de modo que cada persona y cada emoción quedan cerca del 15 % en test.

Relación persona–emoción. La V de Cramér entre persona y emoción es 0,248 ($\chi^2 = 667$, 76 g.l.): cada persona muestra una mezcla distinta de emociones, así que reconocer a la persona da pistas sobre la emoción. Este posible atajo se controla en la sección 6.

2. Pipeline y entrenamiento

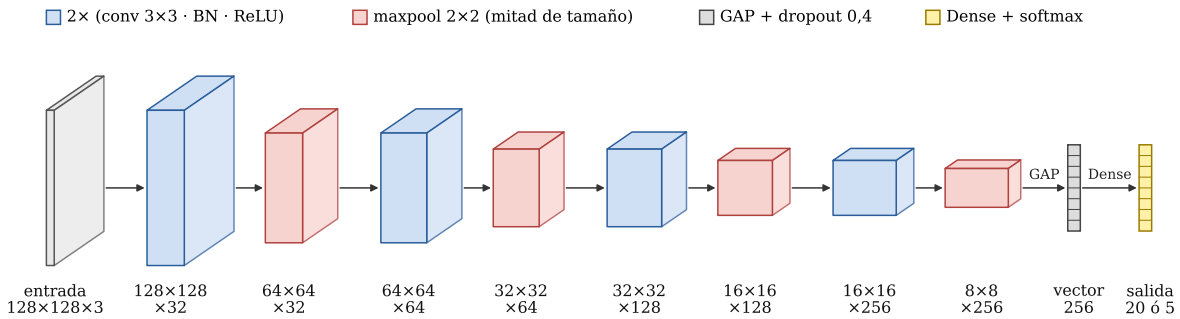
- Pipeline `tf.data` con caché y *prefetch*. Aumentación solo en train: espejo horizontal, rotación de $\pm 11°$, brillo y contraste de ± 10 %. No se usan espejo vertical ni recortes fuertes, que generarían caras o gestos imposibles.
- Pesos por clase balanceados ($n/(K \cdot n_c)$), *early stopping* sobre la pérdida de validación con restauración del mejor modelo, reducción de la tasa de aprendizaje en meseta y precisión mixta.
- **CNNs desde cero:** entrada de 128 px, Adam (10^{-3}), hasta 60 épocas, BatchNorm con *momentum* 0,9.
- **Transfer learning** (pesos de ImageNet, 224 px) en dos fases: primero solo la cabeza nueva (GAP + dropout 0,3 + densa) con la base congelada; después se descongelan las últimas capas con BatchNorm congelada y tasa 10^{-5}.
- Toda decisión (modelo, época, hiperparámetros) se toma con validación; el test se evalúa una sola vez.

3. Arquitecturas desde cero

Las cuatro reciben 128×128×3 y terminan igual: *Global Average Pooling*, dropout 0,4 y una densa con softmax (20 salidas en identidad, 5 en emoción). En los diagramas, cada cubo es el mapa de características de esa etapa: el alto representa el tamaño espacial y el ancho los canales. Al avanzar, la imagen se achica y los canales crecen.

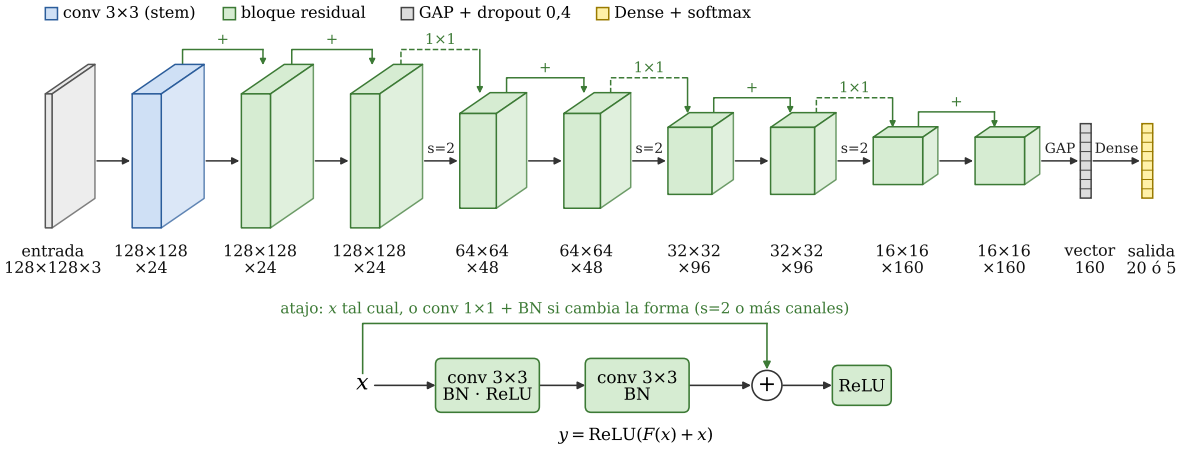
3.1 `cnn`: tipo VGG (1,18 M parámetros, 8 convoluciones)

Cuatro bloques de dos convoluciones 3×3 (Conv–BN–ReLU) y un maxpool que divide el tamaño a la mitad. Es la referencia simple.



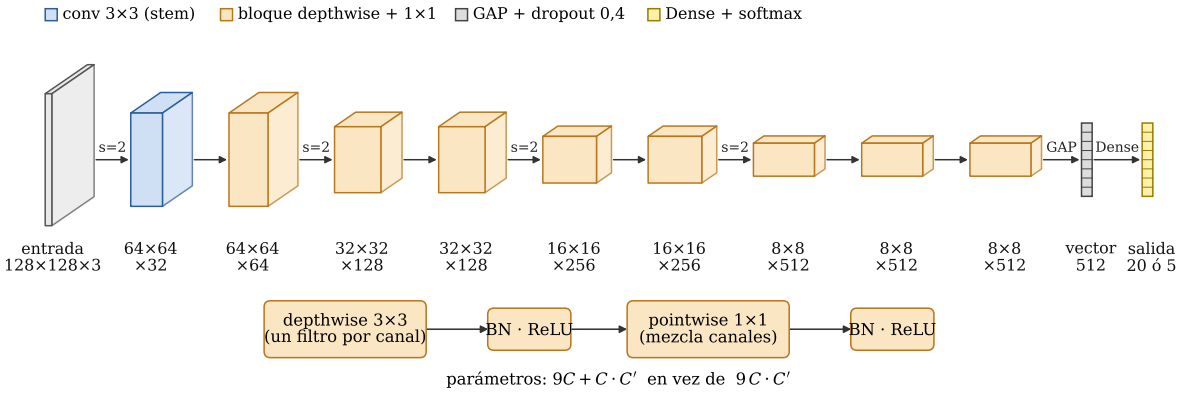
3.2 `cnn_residual`: mini-ResNet (1,24 M, 20 convoluciones)

Ocho bloques residuales en cuatro etapas. Cada bloque suma su entrada a la salida, $y = \mathrm{ReLU}(F(x)+x)$: el gradiente pasa por el atajo sin atravesar las convoluciones, lo que permite más profundidad sin que el entrenamiento se degrade. La resolución baja con convoluciones de paso 2; en esos bloques el atajo usa una conv 1×1 (punteada).



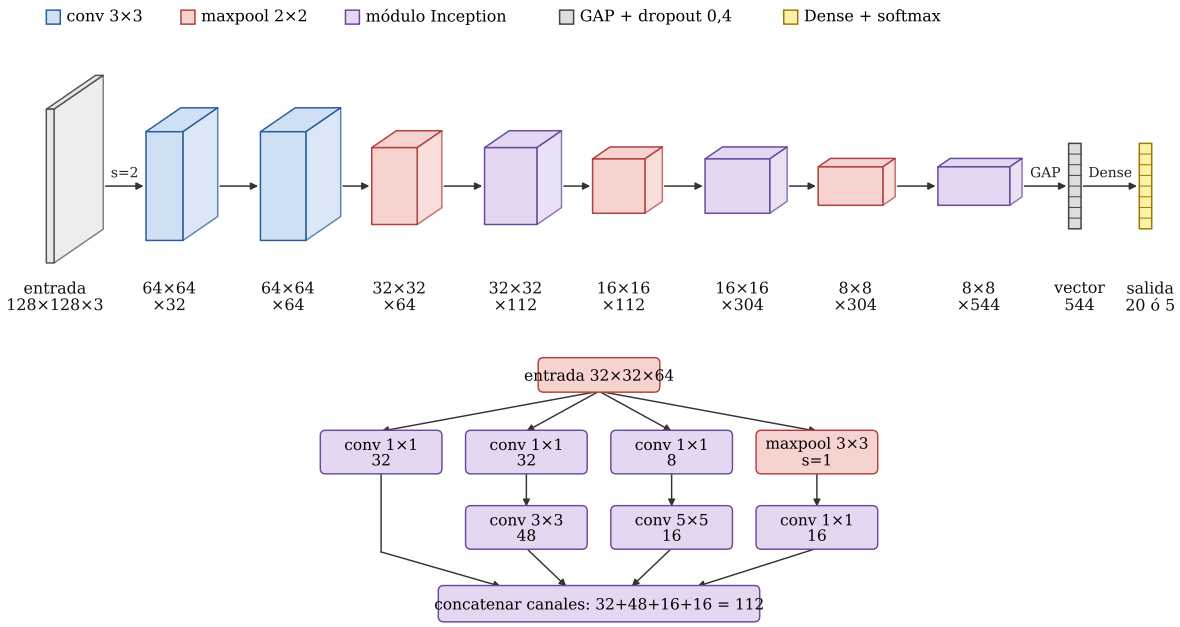
3.3 `cnn_separable`: mini-MobileNet (0,83 M, 17 convoluciones)

Cada bloque separa la convolución en una 3×3 por canal (*depthwise*) y una 1×1 que mezcla canales (*pointwise*): unas 9 veces menos parámetros por capa, y por lo tanto menos capacidad de memorizar.



3.4 `cnn_inception`: mini-Inception (0,57 M, 20 convoluciones)

Cada módulo mira la misma entrada con ramas 1×1, 3×3, 5×5 y maxpool en paralelo y concatena los resultados: ve detalles finos (comisuras, cejas) y la forma global de la cara a la vez. Las 1×1 previas reducen los canales para que las ramas grandes no multipliquen los parámetros.



Detalle del módulo 1 (32×32×64 → 32×32×112); los módulos 2 y 3 tienen 304 y 544 canales de salida.

3.5 Transfer learning y baselines

MobileNetV2 (2,3 M, liviana), EfficientNetB0 (4,1 M, escala profundidad, ancho y resolución juntos) y ResNet50V2 (23,6 M, la referencia grande). Baselines: clase más frecuente (*Dummy*), Random Forest sobre píxeles en gris de 48×48 y, solo para emoción, "solo persona" (predice la emoción más frecuente de cada persona en train).

4. Resultados

		Identidad		Emoción	
Modelo	Tipo	Val	Test	Val	Test
Dummy	baseline	—	0,013	—	0,086
Solo persona	baseline	—	—	—	0,255
Random Forest	baseline	—	0,842	—	0,360
`cnn`	desde cero	0,953	0,959	0,365	0,404
`cnn_residual`	desde cero	0,948	0,955	0,373	0,368
`cnn_separable`	desde cero	0,948	0,945	0,395	0,425
`cnn_inception`	desde cero	0,941	0,959	0,439	0,449
MobileNetV2	transferencia	0,972	0,961	0,449	0,464
EfficientNetB0	transferencia	0,970	0,951	0,390	0,459
ResNet50V2	transferencia	**0,976**	**0,974***	**0,463**	**0,482***

Cuadro 1. F1 macro en validación ($n = 413$) y test ($n = 411$) del dataset final, corrida en TensorFlow sobre Colab T4. * Modelo elegido por validación. Con una sola semilla, diferencias de ±0,02 no son significativas.

- **Identidad:** todos los modelos entrenados quedan entre 0,95 y 0,97 y el Random Forest llega a 0,84: con 20 personas la tarea es fácil. ResNet50V2 es la mejor, pero la CNN Inception empata con la VGG con la mitad de parámetros. Solo 11 de 411 imágenes de test están mal; la confusión más repetida es Tini Stoessel → Lali Espósito (2).
- **Emoción:** gana el transfer learning (0,46–0,48). Entre las CNNs desde cero rinden mejor las de menos parámetros (Inception 0,449 y separable 0,425 frente a 0,37–0,40). Las confusiones más frecuentes son sorpresa → enojo (20), alegría → neutral (18) y sorpresa → neutral (17): gestos sutiles y una clase neutral que absorbe los casos dudosos.
- **G8 dentro del test final** (34 imágenes de Fonzi y Echarri): identidad 94 % de acierto, emoción 47 % (F1 macro

0,366).

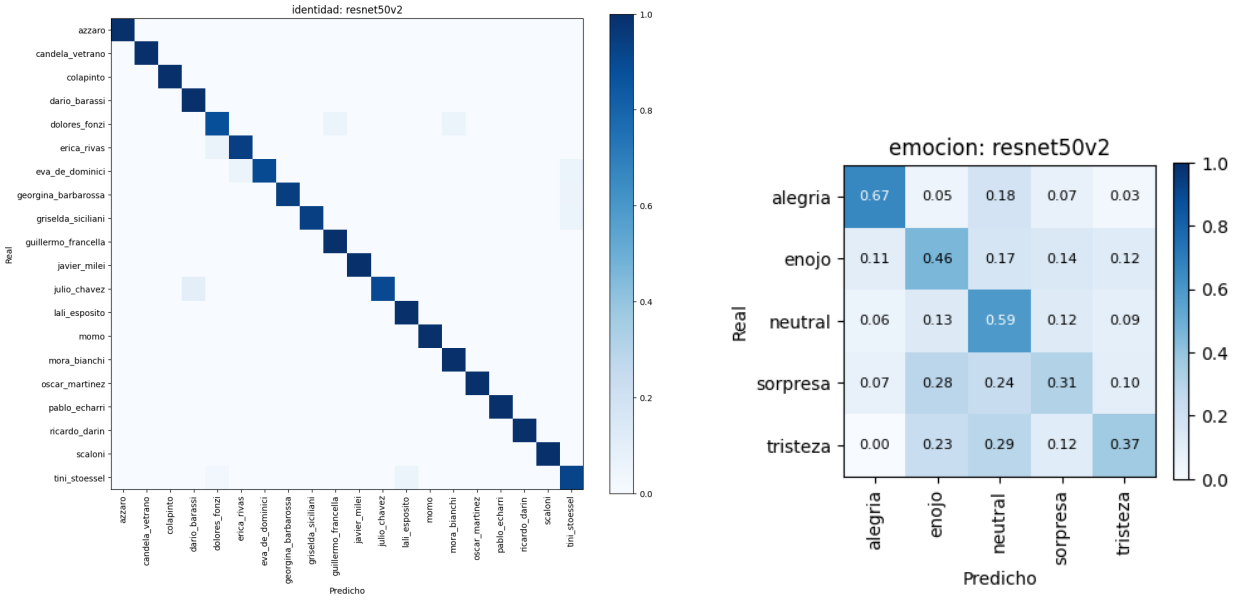


Figura 1. Matrices de confusión en test con ResNet50V2. Izquierda: identidad. Derecha: emoción.

5. ¿Sobreajuste o subajuste?

Se midió, en la mejor época de cada entrenamiento, la brecha entre la exactitud de train y la de validación. Criterio: *sobreajuste* si la brecha supera 0,10 y la pérdida de validación sube después del mínimo (o la brecha supera 0,20); *subajuste* si la exactitud de train no llega a 0,70.

- **Identidad: sin sobreajuste preocupante.** Brecha de 2 a 6 puntos (train 98–100 %, validación 93–97 %). `cnn_residual` y ResNet50V2 llegaron al máximo de épocas todavía mejorando décimas.
- **Emoción, CNNs desde cero: sobreajuste.** Brecha de 13 a 15 puntos y la pérdida de validación sube mientras la de train baja (en `cnn_separable`, train baja de 1,08 a 0,43 y validación sube de 1,49 a 1,79). El *early stopping* restaura la mejor época, así que el modelo guardado no es el sobreajustado.
- **Emoción, transfer learning: subajuste.** Brecha de 13 a 20 puntos, pero la exactitud de train es solo 0,58–0,68: el modelo no logra separar bien las emociones ni siquiera en las imágenes con las que entrena.

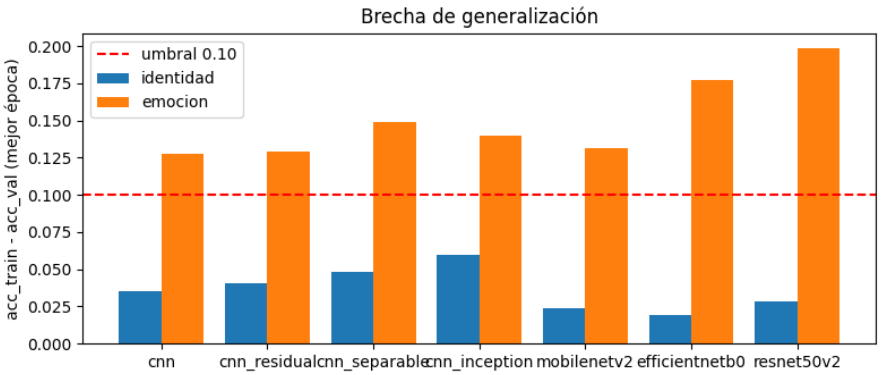


Figura 2. Brecha train – validación en la mejor época. La línea roja es el umbral de 0,10.

La conclusión es que la emoción está limitada por los datos más que por la red: unas 1900 imágenes de train para 5 clases, gestos sutiles y etiquetas discutibles. Duplicar épocas no mejoró en una prueba previa; lo que sí ayudaría es recortar más ajustado a la cara y revisar etiquetas.

6. ¿Qué aprende el modelo?

Atajo persona → emoción. El baseline "solo persona" llega a 0,255, muy por encima del Dummy (0,086), pero ResNet50V2 (0,482) lo supera con claridad, así que aprende gestos. En las 273 imágenes de test cuya emoción no es la habitual de su persona, el modelo acierta el 39 % y repite la emoción habitual el 23 %: el atajo existe, pero es parcial.

Grad-CAM. Se midió qué fracción del mapa de calor cae en el 60 % central de la imagen, donde está la cara (un mapa uniforme da 0,36). En identidad da 0,461: mira la cara, pero también pelo, ropa y textos del video. En emoción da 0,395 en general, 0,420 en los aciertos y 0,369 en los errores: cuando acierta mira más la cara, y cuando se equivoca mira más el fondo.



Figura 3. Grad-CAM de identidad en test (ResNet50V2). Arriba aciertos, abajo errores; el recuadro es la zona central.

Fuga de escena. El *phash* agrupa solo fotogramas casi idénticos; los del mismo video que difieren un poco más pueden quedar en train y en test a la vez. Una partición por escena del mismo dataset da cifras más bajas (identidad ≈0,87, emoción ≈0,37), así que los resultados de la tabla están inflados por este efecto.

Autoencoder. Un autoencoder de 64×64 entrenado sobre las imágenes ayuda a encontrar recortes raros (las peor reconstruidas). Su espacio latente casi no separa ni personas ni emociones (silueta 0,02 y $-0,02$): las diferencias que importan son finas y las aprenden mejor las redes supervisadas.

7. Aplicación web

Los modelos se exportaron a TorchScript (desde la réplica en PyTorch del mismo pipeline) y se publicaron en una aplicación de Streamlit. Permite elegir al azar una foto de test o subir una propia, y muestra las tres personas y las tres emociones más probables. La foto se recorta al cuadrado central y se lleva a 224×224, igual que en el entrenamiento. Con fotos propias rinde mejor si la cara ocupa casi toda la imagen, y siempre elige a una de las 20 personas.

8. Limitaciones y próximos pasos

- Adoptar una partición por escena para todo el grupo y reentrenar, para obtener cifras sin fuga.
- Recortar más ajustado al rostro y revisar a mano los recortes dudosos que detectó el autoencoder.
- Una sola semilla y sin medición del acuerdo entre etiquetadores de emoción.