Clasificación de identidad y emoción en rostros

Trabajo Práctico 1 — Grupo 8

IA y Aprendizaje Automático II · UCA Rosario · Noviembre 2026

Resumen

Se entrenaron clasificadores de imágenes para dos tareas sobre rostros de figuras públicas argentinas: *identidad* (20 personas) y *emoción* (alegría, enojo, neutral, sorpresa y tristeza). Se compararon cuatro CNNs entrenadas desde cero, tres modelos con transfer learning y tres baselines. En el test del dataset final (411 imágenes), la identidad alcanza un F1 macro de 0,97 con una CNN tipo Inception de 0,57 M de parámetros, y la emoción 0,51 con EfficientNetB0. Los análisis muestran que la identidad se apoya en parte en el fondo del video, por lo que esas cifras están algo infladas. El modelo final se publicó en una aplicación web.

1. Datos

- **Dataset final:** 2723 imágenes de 224×224 de 20 personas. **G8:** 221 imágenes de dos personas (Dolores Fonzi y Pablo Echarri), incluidas también en el final.
- **Limpieza:** se eliminaron 10 duplicados exactos (md5) con etiquetas en conflicto; quedan 2713 imágenes.
- **Desbalance:** por persona, de 63 a 419 imágenes; por emoción, de 340 (tristeza) a 765 (neutral). Por eso la métrica principal es el **F1 macro**.
- **Partición 70/15/15** (semilla 42). Los fotogramas casi idénticos de un mismo video se agrupan con un hash perceptual (*phash*, distancia ≤ 8) y cada grupo va entero a una sola partición, para que el test no contenga copias del train. La asignación se hace por persona, de modo que cada persona y cada emoción quedan entre 14,7 % y 15,9 % en test. G8 usa sus filas de esta misma partición (154/33/34).

Relación persona–emoción. La V de Cramér entre persona y emoción es 0,248: cada persona muestra una mezcla distinta de emociones, así que reconocer a la persona da pistas sobre la emoción. Este posible atajo se controla en la sección 5.

2. Pipeline y entrenamiento

- Pipeline `tf.data` con caché y *prefetch*. Aumentación solo en train: espejo horizontal, rotación de $\pm 11°$, brillo y contraste de ± 10 %. No se usan espejo vertical ni recortes fuertes, que generarían caras o gestos imposibles.
- Pesos por clase balanceados, *early stopping* sobre la pérdida de validación con restauración del mejor modelo, reducción de la tasa de aprendizaje en meseta y precisión mixta.
- **CNNs desde cero:** entrada de 128 px, Adam (10^{-3}), hasta 60 épocas.
- **Transfer learning** (pesos de ImageNet, 224 px) en dos fases: primero solo la cabeza nueva con la base congelada; después se descongelan las últimas capas con BatchNorm congelada y tasa 10^{-5}.
- Toda decisión (modelo, época, hiperparámetros) se toma con validación; el test se evalúa una sola vez.

La entrega está en TensorFlow/Keras para Colab (GPU T4). Al agotarse el cupo de GPU de Colab, se escribió una réplica en PyTorch con las mismas decisiones para entrenar en una GPU local; ambas dan el mismo resultado numérico con los mismos pesos. Las cifras del dataset final provienen de esa réplica.

3. Modelos

Modelo	Tipo	Parám.	Motivo de la elección
`cnn`	tipo VGG (Conv–BN–ReLU)	1,18 M	referencia clásica y simple
`cnn_residual`	mini-ResNet (conexiones residuales)	1,24 M	más profundidad sin perder gradiente
`cnn_separable`	mini-MobileNet (convoluciones separables)	0,83 M	menos parámetros, menos sobreajuste
`cnn_inception`	mini-Inception (ramas 1×1, 3×3, 5×5)	0,57 M	mira la cara a varias escalas
MobileNetV2	transfer learning	2,3 M	liviana y eficiente
EfficientNetB0	transfer learning	4,1 M	buen equilibrio tamaño/precisión
ResNet50	transfer learning	23,6 M	referencia de gran tamaño

Cuadro 1. Modelos comparados. Baselines: clase más frecuente (*Dummy*), Random Forest sobre píxeles en gris de 48×48 y, solo para emoción, "solo persona" (predice la emoción más frecuente de cada persona en train).

4. Resultados

	Dataset final (test, $n = 411$)		G8 (test, $n = 34$)	
Modelo	Identidad	Emoción	Identidad	Emoción
Dummy	0,013	0,086	0,333	0,084
Solo persona	—	0,255	—	—
Random Forest	0,874	0,380	0,912	0,272
`cnn`	0,959	0,333	0,911	0,215
`cnn_residual`	0,952	0,248	—	—
`cnn_separable`	0,954	0,443	—	—
`cnn_inception`	**0,971**	0,437	—	—
MobileNetV2	0,952	0,484*	0,881	**0,304**
EfficientNetB0	0,962*	**0,509**	**0,941**	0,134
ResNet50	0,960	0,462	0,911*	0,250

Cuadro 2. F1 macro en test. * Modelo elegido por validación. G8 se corrió en Colab antes de agregar las tres CNNs nuevas. Con una sola semilla, diferencias de ±0,02 no son significativas.

- **Identidad:** todos los modelos entrenados quedan entre 0,95 y 0,97. La CNN Inception, la más chica, es la mejor: para 20 personas no hace falta una red grande. La confusión más frecuente es entre Tini Stoessel y Lali Espósito.
- **Emoción:** gana el transfer learning (0,46–0,51). Entre las CNNs desde cero rinden mejor las de menos parámetros (0,44 frente a 0,33 de la VGG): con unas 1900 imágenes de train, menos parámetros implica menos sobreajuste. Alegría es la emoción más fácil (la sonrisa es muy marcada) y enojo la más difícil.
- **G8** tiene muy pocas imágenes para emoción: todos los modelos quedan cerca del azar.

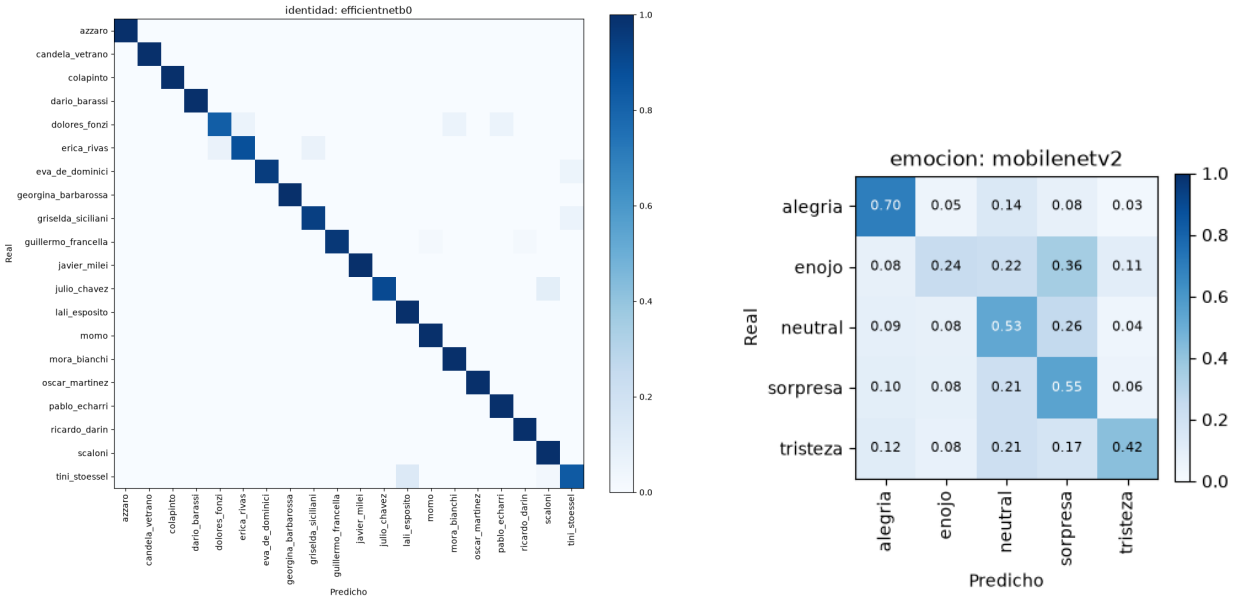


Figura 1. Matrices de confusión normalizadas por fila (test del dataset final). Izquierda: identidad (EfficientNetB0). Derecha: emoción (MobileNetV2).

5. ¿Qué aprende el modelo?

Atajo persona → emoción. El baseline "solo persona" llega a 0,255, muy por encima del Dummy (0,086), pero los mejores modelos (0,48–0,51) lo superan con claridad, así que aprenden gestos. En las 273 imágenes de test cuya emoción no es la habitual de su persona, el modelo acierta el 37 % y repite la emoción habitual el 27 %: el atajo existe, pero es parcial.

Grad-CAM. Se midió qué fracción del mapa de calor cae en el 60 % central de la imagen, donde está la cara (un mapa uniforme da 0,36). En identidad da 0,356: el modelo usa también pelo, ropa y fondo del video. En emoción da 0,442: mira más la cara, en especial boca y ojos.

Fuga de escena. El *phash* agrupa solo fotogramas casi idénticos; los del mismo video que difieren un poco más pueden quedar en train y en test a la vez. Una partición por escena del mismo dataset da cifras más bajas (identidad ≈0,87, emoción ≈0,37), así que los resultados de la tabla están inflados por este efecto.

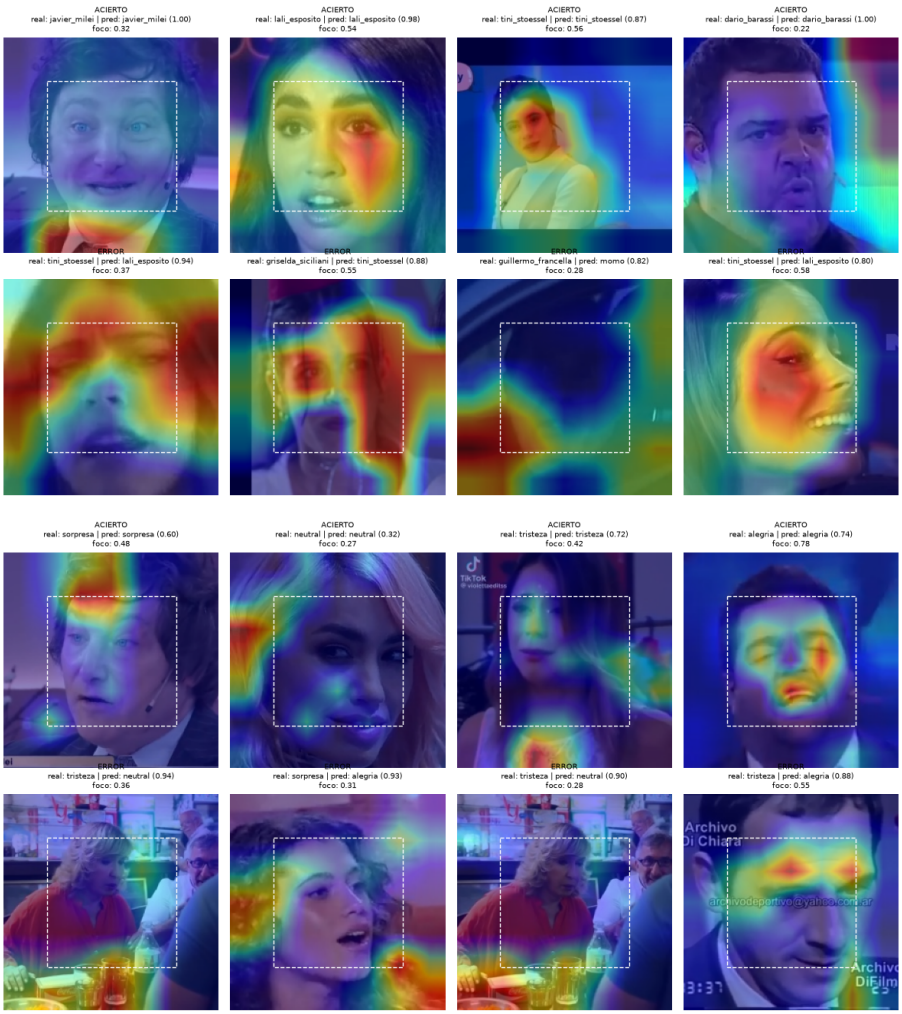


Figura 2. Grad-CAM en test. Arriba: identidad. Abajo: emoción. En cada grilla, la fila superior son aciertos y la inferior errores.

6. Aplicación web

Los modelos elegidos (CNN Inception para identidad y MobileNetV2 para emoción) se exportaron a TorchScript y se publicaron en una aplicación de Streamlit. Permite elegir al azar una foto de test o subir una propia, y muestra las tres personas y las tres emociones más probables. La foto se recorta al cuadrado central y se lleva a 224×224, igual que en el entrenamiento; con fotos de test reproduce las cifras de la tabla (0,966 y 0,506 de exactitud). Con fotos propias rinde mejor si la cara ocupa casi toda la imagen, y siempre elige a una de las 20 personas.

7. Limitaciones y próximos pasos

- Adoptar una partición por escena para todo el grupo y reentrenar, para obtener cifras sin fuga.
- Correr el notebook de TensorFlow sobre el dataset final en Colab T4.
- Recortar más ajustado al rostro y revisar a mano los recortes dudosos que detectó el autoencoder.
- Una sola semilla y sin medición del acuerdo entre etiquetadores de emoción.